EDA 리포트

주제 주말 베이커리 카페 팝업스토어 어디에 열까? — 주말 유동인구 대비 카페·베이커리 매출 × 임대료로 고른 후보 상권
작성 이지민 · ABA3 1차 프로젝트 (유통) · 2026-10-22
대시보드 https://zmnl-debug.github.io/weekend-bakery-popup/

> 이 리포트는 데이터 개요, 전처리와 그 근거, 주요 변수의 분포와 관계를 정리한다. 숫자마다 계산 기준(분자·분모·단위·기간)은 `references/metric_definitions.md` , 가설별 판정 기록은 `references/hypothesis_log.md` 에 있다.

---

1. 데이터 개요

항목	내용
출처	서울열린데이터광장「서울시 상권분석서비스」(서울특별시)
사용 파일	추정매출-상권(2021~2025 연도별), 길단위인구-상권, 직장인구-상권, 상주인구-상권, 점포-상권(2021~2025 연도별), 집객시설-상권, 상권변화지표-상권
분석 단위	상권 × 분기 (`상권_코드` + `기준_년분기_코드`)
기간	2021년 1분기 ~ 2025년 4분기 (20개 분기, 매출·점포 기준)
분석 업종	카페·베이커리 = `커피-음료` + `제과점` 합산. 데이터에 '베이커리 카페'가 별도 업종으로 없어 두 업종 합산을 베이커리 카페 시장의 대리 지표로 쓴다
매출의 성격	카드 결제 기반 **추정** 매출, 물가 미반영(명목) 금액. 온라인 매출 미포함

핵심 지표 — 주말 유동인구 1천 명당 주말 카페·베이커리 매출 (원, 상권 × 분기)

```
= 카페·베이커리 주말_매출_금액 ÷ ((토요일_유동인구_수 + 일요일_유동인구_수) ÷ 1,000)
```

매출에는 배달·동네 주민·법인카드 결제가 섞여 있어, 결제자가 지나간 사람인지 알 수 없다. 그래서 '전환율'이 아니라 **유동인구 대비 매출 효율**로 해석한다.

---

2. 데이터 결합과 전처리

2-1. 결합

단계	결과
추정매출-상권 2021~2025 이어 붙이기	439,141행 × 57열, 20개 분기 모두 존재, 결측·매출 0 이하 0건
카페·베이커리만 골라 상권 × 분기로 합산	21,972행 (두 업종 모두 있는 조합 8,363 / 한 업종만 13,609)
인구·점포·시설·상권변화 파일 결합 (왼쪽 결합)	파일별 미매칭 11~331행은 빈칸으로 유지 (신설 상권 등)

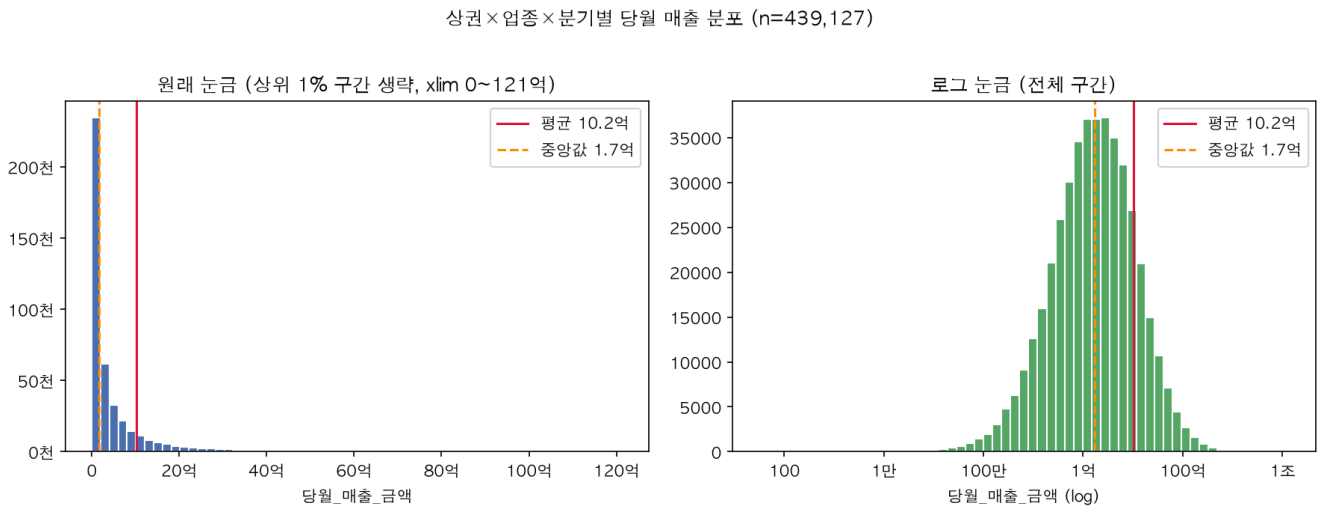
- 상권 수는 연도별 1,576~1,581개로 거의 같고, 1,560개 상권이 5년 내내 있다 → 시간 순 분할에 문제 없음
- 업종 `고시원`은 2023년까지만 있어 전체 업종 분석에서 제외 (카페·베이커리 분석과는 무관)

2-2. 전처리 규칙과 근거

항목	처리	근거
파일 인코딩·열 이름	`cp949`로 읽고, 2025년 점포 파일의 영문 열 이름(`stdr_yyqu_cd` 등)을 한글 열 이름으로 맞춤	그대로 이어 붙이면 같은 내용이 다른 열로 갈라짐
분기 코드	`기준_년분기_코드`를 연도(`//10`)·분기(`%10`)로 분리	20214 다음이 20221이라 그냥 정렬하면 순서가 어긋남
주말 유동인구가 너무 작은 행	주말 유동인구 하위 1%(8,666명 미만, 220행) 제외	분모가 작아 지표가 폭발 — 예: 청계산원터골은 주말 유동인구 8~700명인데 1천 명당 매출이 최대 72억 원. 산·하천 주변에서 길단위 유동인구가 거의 잡히지 않는 데이터 한계로 판단
집객시설 세부 열 빈칸	0으로 채움 (집객시설 파일과 매칭된 행만)	원본 파일에 0이 하나도 없고 빈칸만 있음 → 빈칸 = 시설 없음
주말 매출 0원 (246행)	유지, 로그는 log(1 + x)	실제로 주말 매출이 없는 상권일 수 있음
카페 점포 수	`유사_업종_점포_수` 사용	`유사_업종_점포_수` = `점포_수` + `프랜차이즈_점포_수` (전 행 일치). `점포_수`는 프랜차이즈를 뺀 값
연령대 비중의 분모	연령을 알 수 있는 매출 합계	연령 미상 매출(법인카드 등) 비율이 업종마다 다름 (2024년 카페 12.9%, 한식 21.3%)

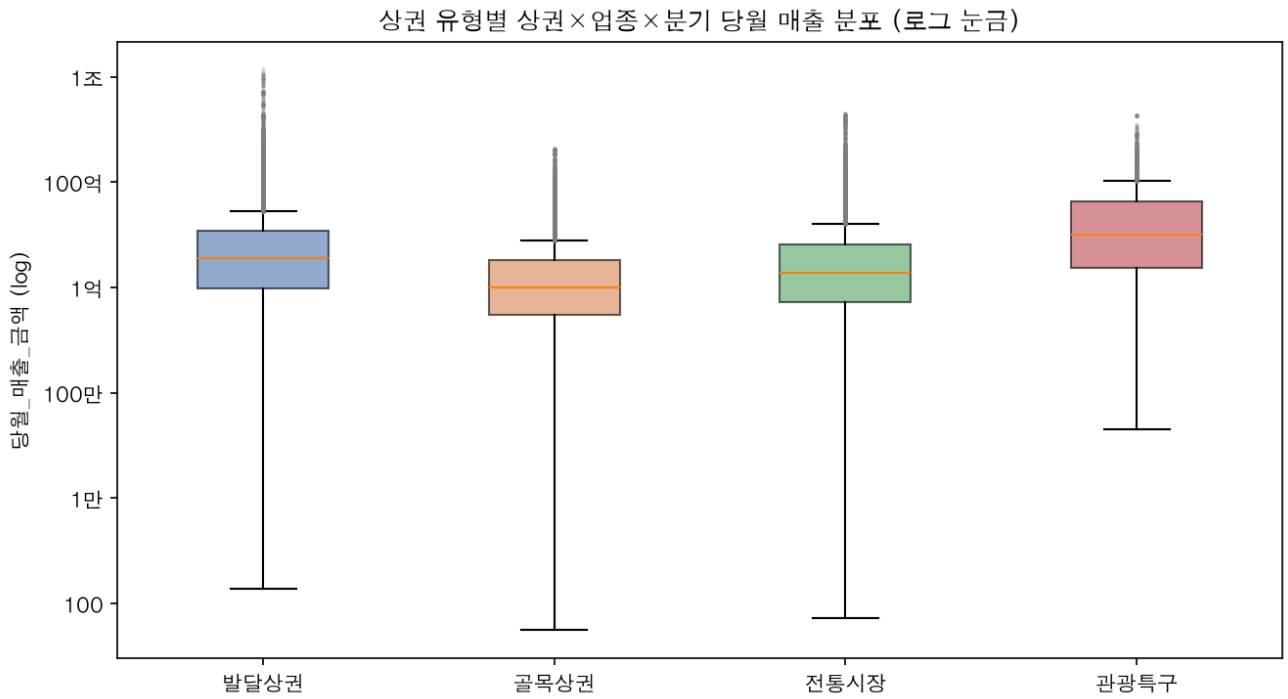
3. 분포

3-1. 전체 상권 × 업종 매출 — 오른쪽으로 크게 치우침



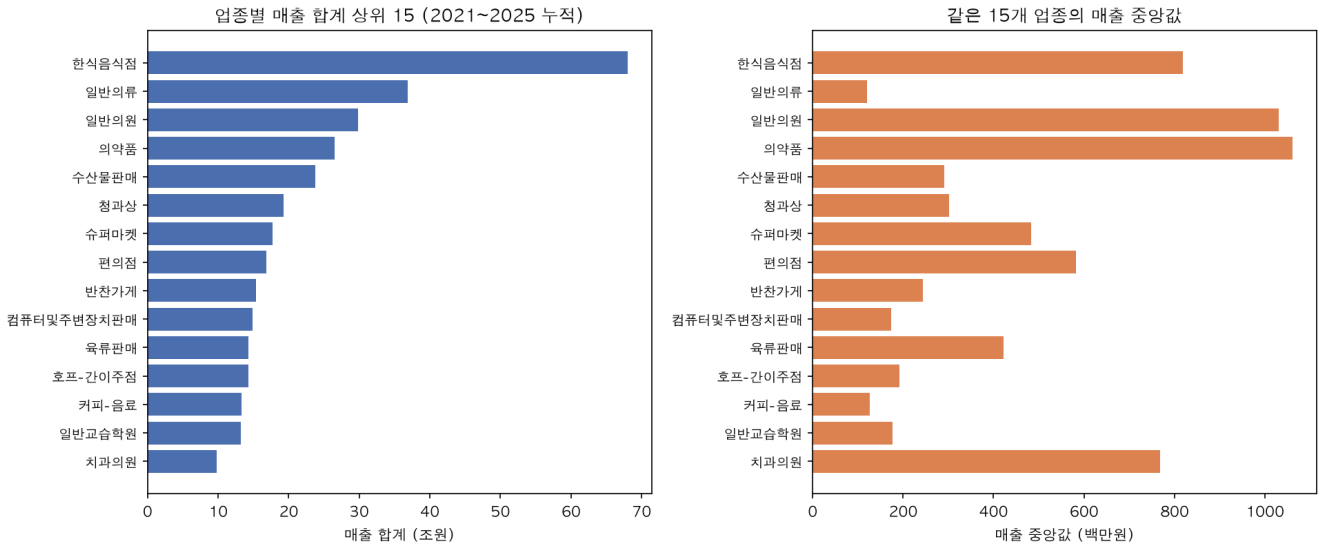
평균 10.2억 원, 중앙값 1.7억 원으로 평균이 중앙값의 6배다. 로그 눈금에서 1억 원 근처를 중심으로 종 모양이 되어, 이후 모델 타겟에는 로그를 씌운다.

3-2. 상권 유형별 매출 — 상권 수와 매출 규모가 반대



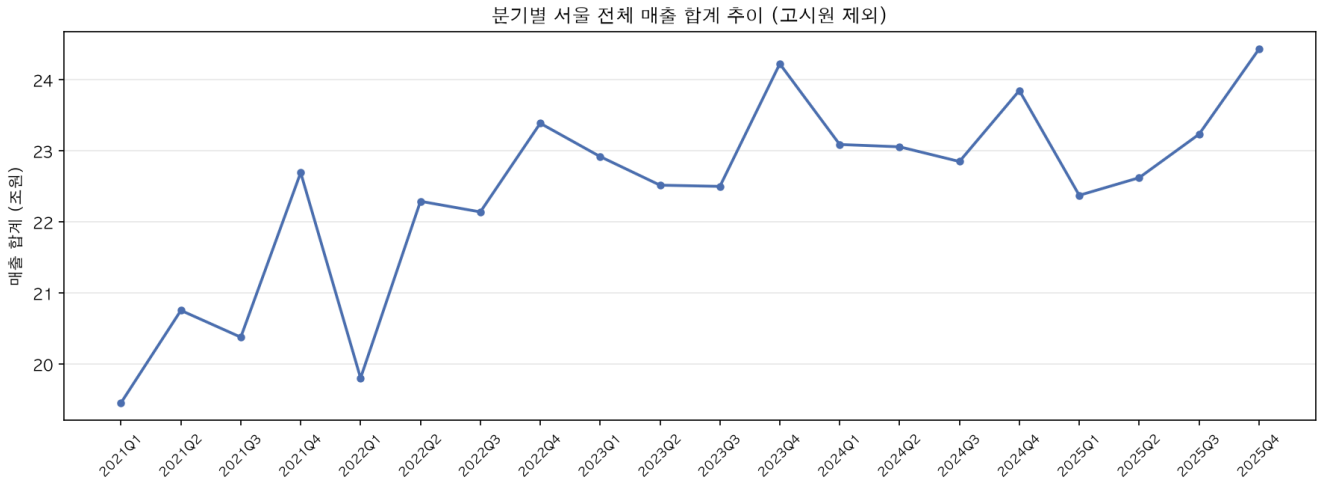
발달상권은 상권 수 16%로 매출 62%를, 골목상권은 상권 수 66%로 매출 18%를 차지한다. 상권당 중앙값은 관광특구 > 발달 > 전통시장 > 골목 순이다.

3-3. 업종별 매출 — 합계 순위와 업종당 매출이 다름



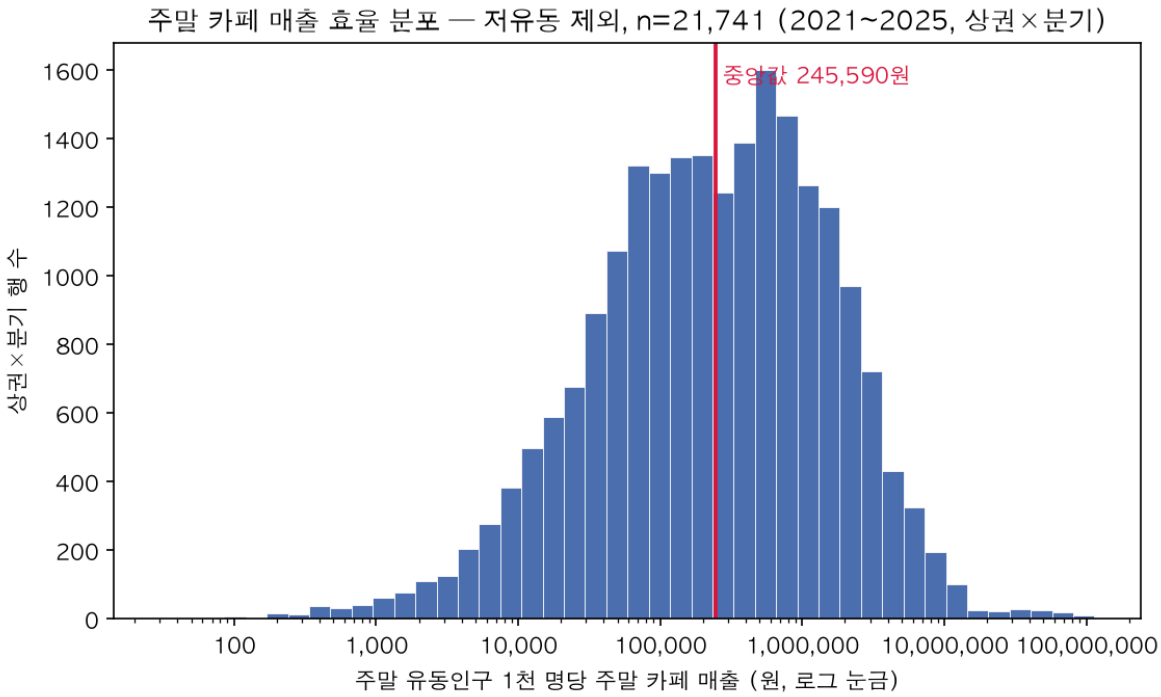
일반의류는 합계 2위지만 중앙값 1.2억 원(매장이 많아서 합계가 큼), 의약품·일반의원은 중앙값 10억 원 이상(매장 하나가 큼)이다.

3-4. 분기별 추이 — 4분기 계절성, 명목 기준 증가



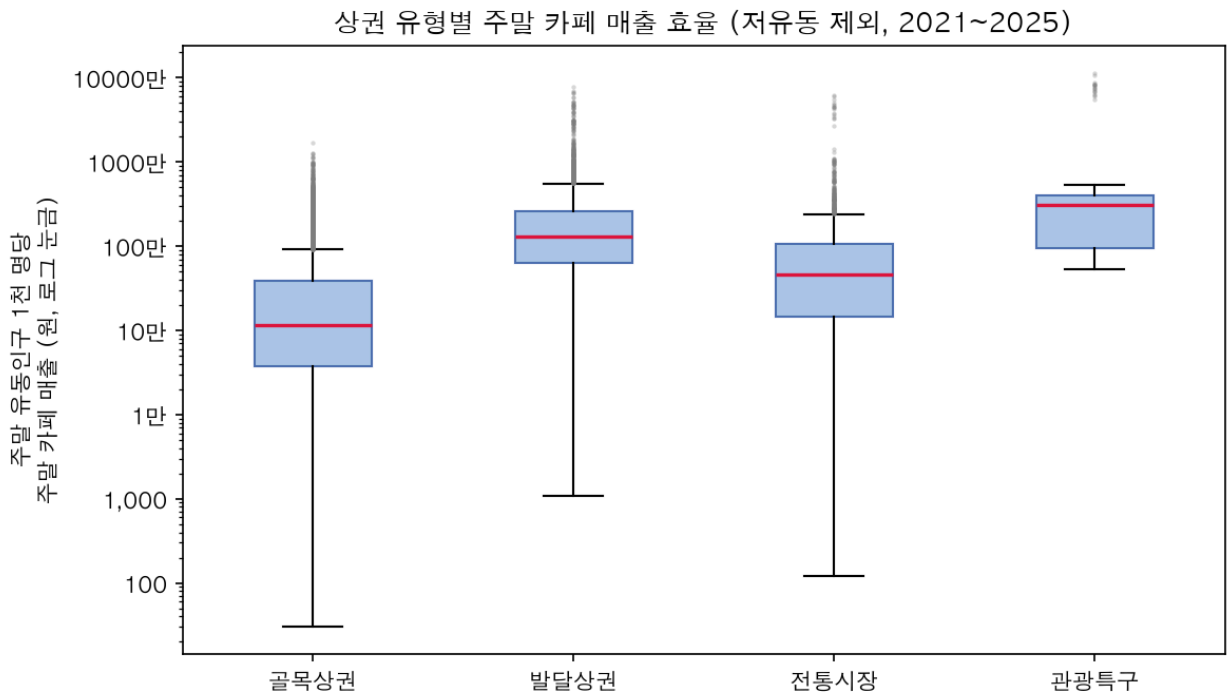
매년 4분기가 가장 높다. 2021년 1분기 19.5조 원 → 2025년 4분기 24.4조 원으로 **명목 기준** +25.6%이며, 물가가 반영되지 않아 실질 성장으로 단정하지 않는다.

3-5. 핵심 지표(주말 효율) 분포 — 상권 간 차이가 큼



상권 × 분기 21,741건(저유동 제외 후)에서 중앙값 약 24.6만 원, 상위 25% 경계가 하위 25% 경계의 약 15배다. 예를 들어 2025년 골목상권 중 1년간 주말 유동인구가 비슷한 마포FM(86만 명)과 수락산디자인거리(95만 명)의 1년간 주말 카페·베이커리 매출(4개 분기 합계)은 0.06억 원 vs 6.18억 원으로 약 100배 차이 난다.

3-6. 상권 유형별 주말 효율



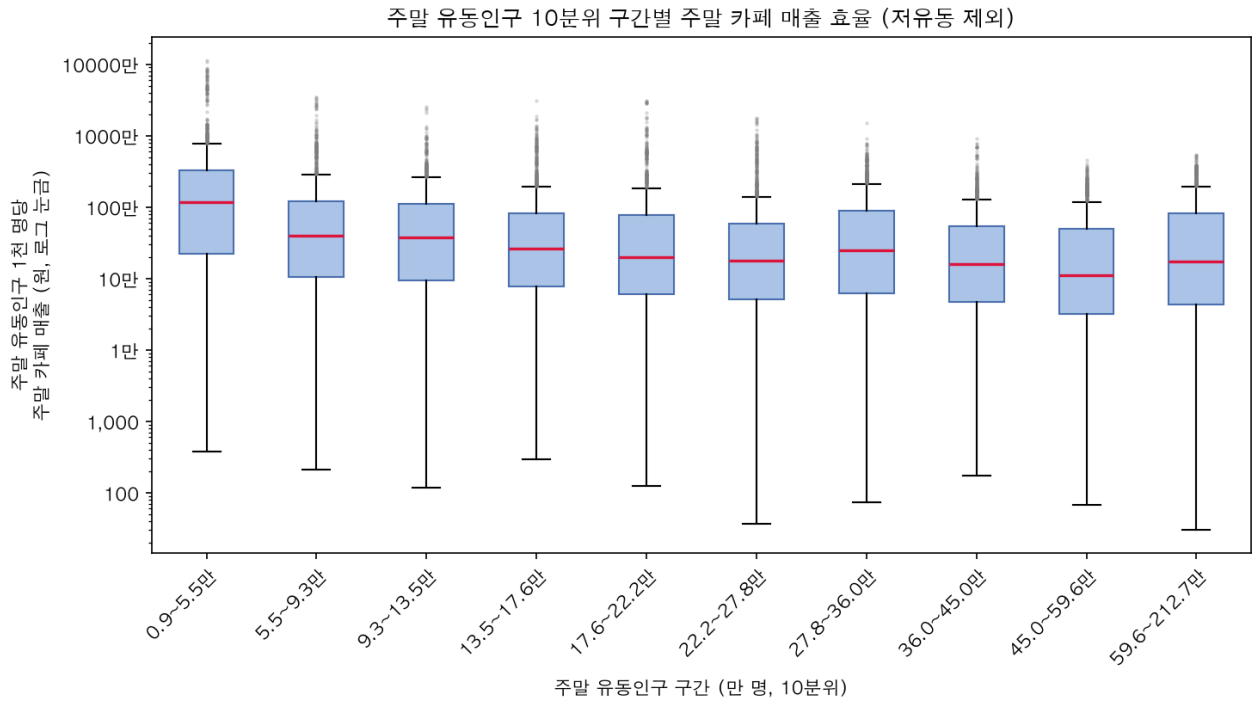
중앙값(2025년, 상권 단위)은 관광특구 319만 원 · 발달 138만 원 · 전통시장 51만 원 · 골목 12만 원이다. 이 차이는 누구나 예상하는 **기본 조건**이라, 이후 분석은 상권 유형을 통제한 뒤 남는 차이를 본다.

---

4. 변수 사이의 관계 (가설 확인)

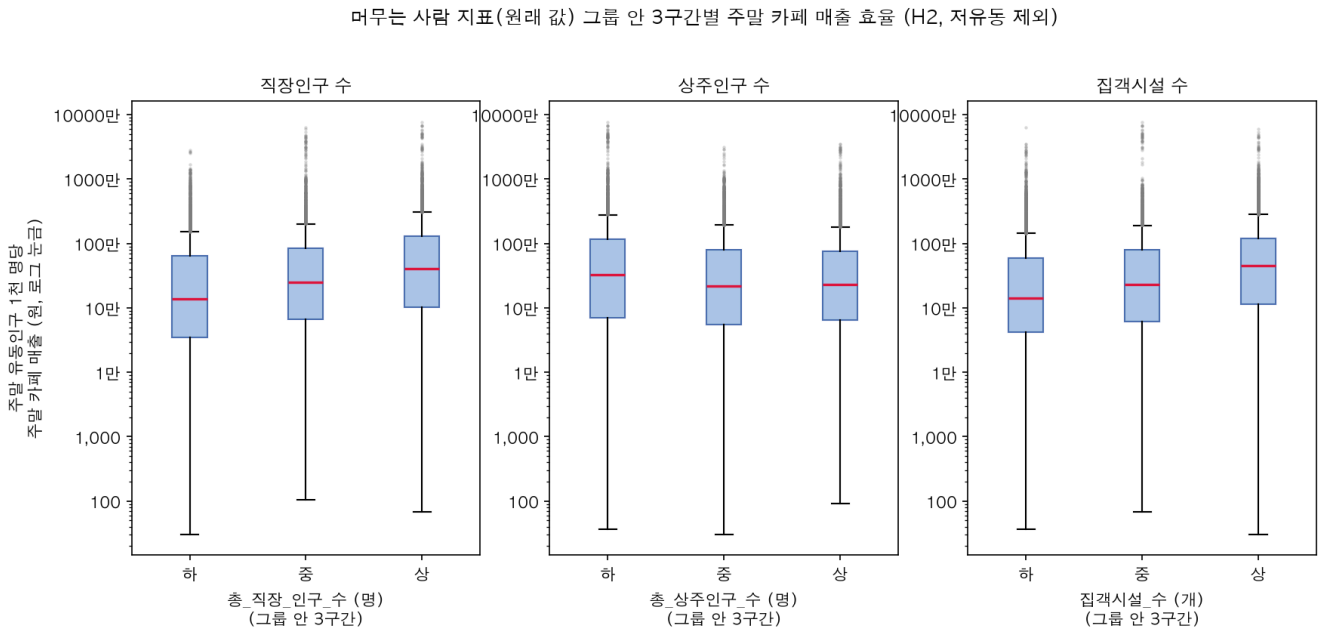
> 아래는 모두 **상관관계**이며 인과가 아니다. 가설별 판정 과정은 `references/hypothesis_log.md` 참고.

가설 1 — 주말 유동인구가 많다고 주말 효율이 높은 것은 아니다 → 지지



- 주말 유동인구와 주말 카페·베이커리 **매출**의 스피어만 상관은 0.24로 약하다 → 사람이 많이 지나간다고 매출이 비례해서 늘지 않는다
- 유동인구가 많은 구간일수록 1천 명당 매출은 오히려 낮다(스피어만 −0.21; 골목 −0.29, 발달 −0.22, 전통시장 −0.22)
- 단, 지표의 분모가 유동인구라 매출이 유동인구만큼 늘지 않으면 음의 관계가 수식상 생긴다 → "많을수록 나쁘다"가 아니라 **"많다고 좋은 건 아니다"**까지만 주장

가설 2 — 머무는 사람이 많은 상권이 효율이 높다 → 부분 지지

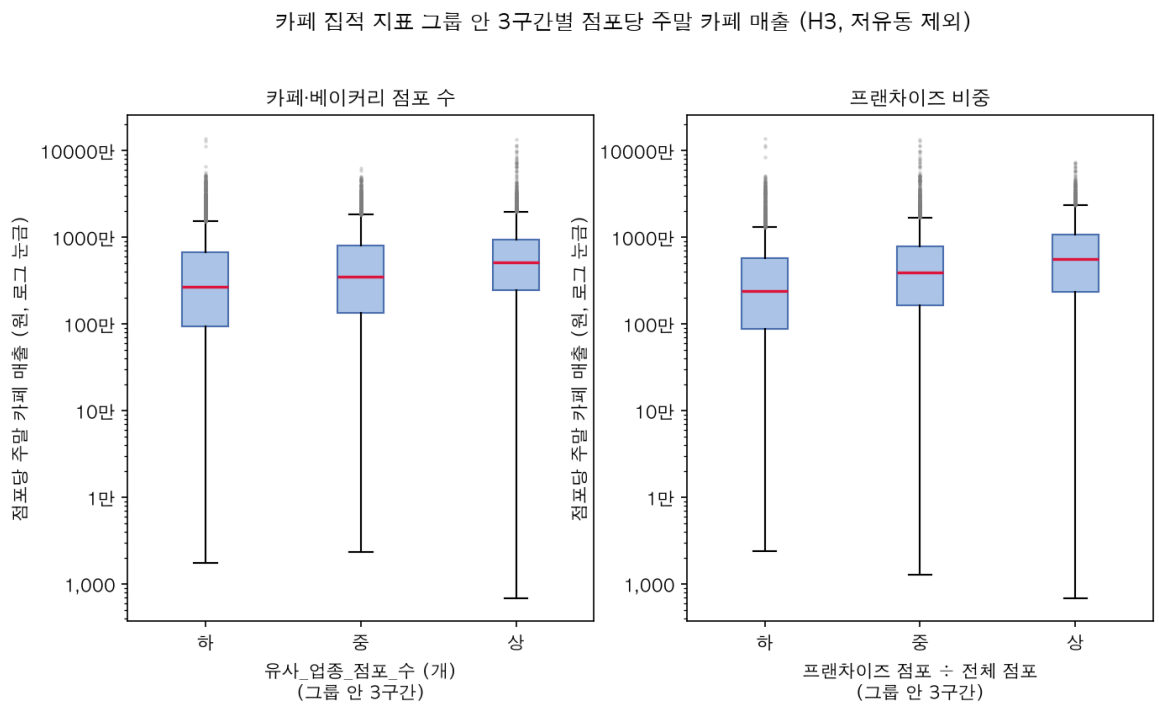


상권 유형 × 주말 유동인구 5분위 그룹 안에서 비교했다.

변수 (원래 값)	하 → 상 구간 중앙값	그룹 안 스피어만
직장인구	2.9배	0.31
집객시설 수	3.2배	0.35
상주인구	0.7배	−0.04 (무관)

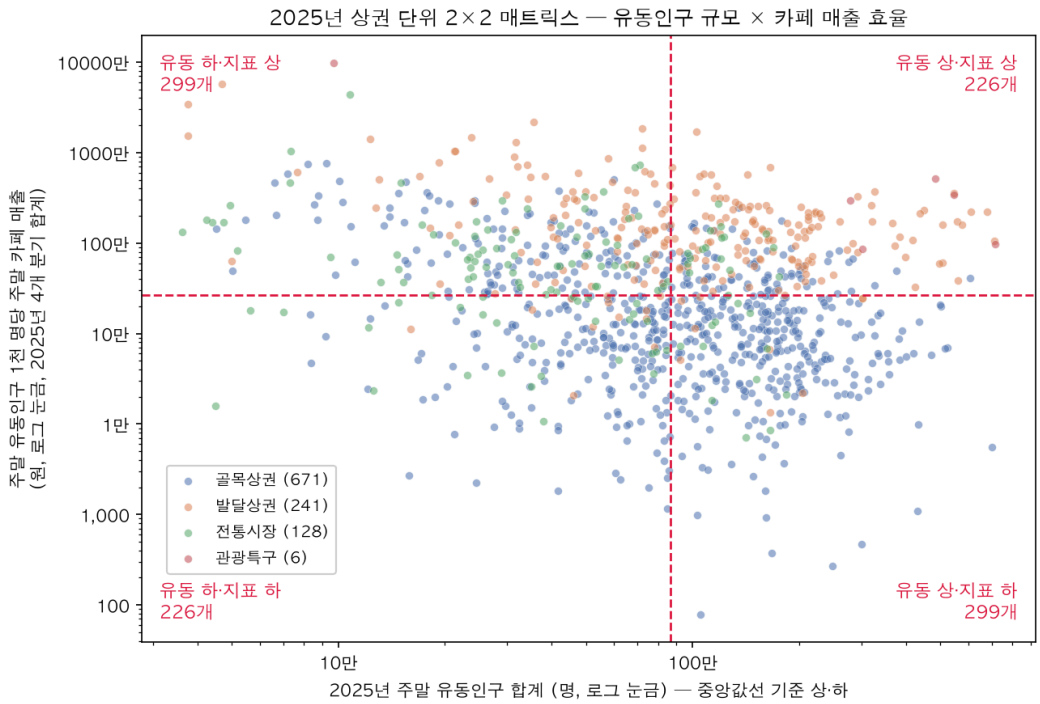
> **트러블슈팅** — 처음엔 '직장인구 ÷ 주말 유동인구' 같은 비율로 봤는데, 지표와 분모가 같아 상관이 부풀려졌다(무작위 값을 유동인구로 나눠도 상관 0.15). 비율 대신 원래 값으로, 같은 유형·같은 유동인구 수준끼리 다시 비교했다 (직장인구 0.55 → 0.31).

가설 3 — 카페·베이커리가 몰린 상권은 손님을 나눠 먹기보다 더 끌어온다 → 약하게 지지



점포가 많으면 합계 매출이 커지는 건 당연하므로, 타겟을 **점포당 주말 매출**로 바꿔 같은 그룹 안에서 비교했다. 점포 수 하 → 상 구간에서 점포당 주말 매출 중앙값이 1.9배(스피어만 0.26)로, 잠식보다는 집적 쪽이다. 프랜차이즈 비중(0.30)은 점포 수 분모를 공유해 부풀려졌을 수 있어 판정을 보류했다.

참고 — 주말 유동인구 × 효율 2×2



'유동인구 상 + 효율 상' 상위 30개 중 25개가 발달상권(잠실역·명동 등)이었다. 상권 유형이라는 기본 조건이 그대로 드러나, 후보 선정은 모델의 '기대 대비 효율'로 하기로 했다.

5. EDA에서 모델링으로

- 효율은 분기 사이에 거의 변하지 않아, **다음 분기**는 "지난 분기 그대로"를 이기기 어려웠다(RMSLE 0.670 vs 상권 조건을 더한 모델 0.676).
- **1년 뒤**를 예측하면 상권 조건을 더한 모델이 기준선 대비 오차를 5.2% 줄였다(0.938 → 0.890). → 메인 타겟을 1년 뒤 효율로 정했다 (모델링 보고서에서 상세).
- 1년 뒤 모델에서 조건 변수의 방향(부분 의존도·선형회귀 부호가 일치한 것): 카페·베이커리 점포 수 **+**, 프랜차이즈 비중 **+**, 직장인구 **+**, 집객시설 수 **−**, 지하철역 수 **−** (`notebooks/2.3-feature-direction.ipynb`).

---

6. 한계

- 매출·유동인구 모두 추정치이며 매출은 명목 금액이다.
- 카페·베이커리 합산은 베이커리 카페의 대리 지표이고, 제과점에는 프랜차이즈 베이커리(생활형 구매)가 섞여 있다.
- 분석 단위가 상권이라 결론은 상권 선택에만 쓴다(점포 하나의 결정으로 옮기지 않음).
- 상관관계이며 인과가 아니다.

데이터 출처

- 서울열린데이터광장「서울시 상권분석서비스」(서울특별시) — https://data.seoul.go.kr/dataList/3/literacyView.do
- (모델링·인사이트 단계 외부 데이터) 한국부동산원「상업용부동산 임대동향조사」소규모상가 임대료 (공공데이터포털), 네이버 데이터랩 검색어 트렌드